

Benchmark Cross-Paradigma e Sintesi Teorica in Giochi su Grafo a Informazione Imperfetta: Studio Sperimentale su Ticket to Ride mediante Torneo a 5.130 Partite

Christian Carminati

Ricerca Indipendente in Intelligenza Artificiale

TicketToRide RL Lab

Settembre 2026

Sommario

I giochi da tavolo strategici a informazione imperfetta definiti su topologie geografiche dinamiche costituiscono uno dei banchi di prova più complessi per l'Intelligenza Artificiale contemporanea. Essi fondono parziale osservabilità, spazi di azione combinatori, instradamento multi-obiettivo a lungo orizzonte e contesa avversaria asimmetrica. Nel presente studio di ricerca indipendente viene condotta un'indagine formale ed empirica sul gioco *Ticket to Ride*. Il problema viene formulato come un Processo Decisionale di Markov Parzialmente Osservabile (POMDP) con mascheramento esplicito delle azioni (*Action Masking*) su un tensore di osservazione a 356 dimensioni e 85 azioni discrete. Vengono implementati e confrontati sei paradigmi: (i) Euristiche Algoritmiche (Uniform Random, Greedy Score e Strategic Dijkstra su cammini minimi), (ii) Deep Reinforcement Learning model-free (Double-DQN e CleanRL PPO con GAE), (iii) Memoria Ricorrente (LSTM-PPO per il tracciamento temporale delle credenze), (iv) Multi-Agent Self-Play con pool storico (PFSP), (v) Information-Set Monte Carlo Tree Search (IS-MCTS) guidato da inferenza Bayesiana degli obiettivi avversari, e (vi) Neural Tree Search (AlphaZero Policy-Value Dual Head con PUCT). A valle di regimi di addestramento a 1.000.000 di passi ambientali e di un torneo esaustivo all'italiana su 5.130 partite (30 scontri diretti per coppia su 19 configurazioni), emerge un netto trilemma prestazionale: l'euristica esatta di Dijkstra si attesta al vertice assoluto (Elo 1329.6, 80.6% di vittorie) grazie a un'approssimazione efficiente dell'albero di Steiner, mentre AlphaZero guida tutti i modelli ad apprendimento neurale (Elo 1275.3, 67.4% di vittorie), seguito con eccezionale stabilità da CleanRL PPO (Elo 1256.1, 63.1% di vittorie). L'analisi di ablazione rivela inoltre come il filtro Bayesiano riduca rapidamente l'entropia di Shannon da 4.15 a 1.37 bit (oltre il 60% di incertezza rimossa nella contesa iniziale), sopprimendo l'errore di *Strategy Fusion* nel tree search.

Parole Chiave: Reinforcement Learning, Processi Decisionali Parzialmente Osservabili (POMDP), Information-Set MCTS, AlphaZero, Proximal Policy Optimization, Opponent Modeling, Algoritmi su Grafo.

1 Introduzione e Motivazione Scientifica

La presa di decisione sequenziale in condizioni di incertezza e informazione incompleta rappresenta il cuore dell'Intelligenza Artificiale moderna [11]. Mentre giochi a informazione perfetta come Scacchi e Go sono stati risolti attraverso combinazioni di reti neurali profonde e ricerca ad albero Monte Carlo (MCTS) [9, 10], i domini a informazione nascosta con risorse condivise su rete spaziale introducono sfide teoriche non banali.

In *Ticket to Ride*, due o più contendenti agiscono su una rete ferroviaria $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ con l'obiettivo di collegare coppie riservate di città (*biglietti di destinazione*) e accumulare punteggio rivendicando tratte. L'ambiente è un POMDP intrinseco: le carte vagone pescate e i biglietti obiettivo degli avversari sono rigorosamente celati. Rivelare prematuramente le proprie intenzioni tramite tratte intermedie espone al blocco tattico dell'avversario; viceversa, fallire il completamento di un biglietto comporta una severa penalizzazione in punti negativi al termine della partita.

Il presente studio risponde formalmente a quattro domande di ricerca (RQ_1 – RQ_4):

- RQ₁** (*Memoria Neurale Implicita vs. Esplicita*): In che misura una policy ricorrente con memoria LSTM supera una policy priva di stato interno nell'inferire strategie latenti in ambiente POMDP?
- RQ₂** (*Risoluzione della Strategy Fusion*): L'integrazione di un filtro Bayesiano basato sull'analisi dei detour su grafo elimina le patologie di determinizzazione casuale nell'Information-Set MCTS [1]?
- RQ₃** (*Trilemma dei Paradigmi*): Qual è la distanza competitiva tra euristiche algoritmiche esatte (Dijkstra), metodi Model-Free Actor-Critic (PPO) e MCTS Neurale (AlphaZero)?
- RQ₄** (*Frontiera di Efficienza Computazionale*): Qual è il costo computazionale (latenza di inferenza in millisecondi per mossa) associato al guadagno di punteggio Elo?

2 Formulazione Matematica del POMDP su Grafo

L'ambiente di gioco a due giocatori è formalizzato come una tupla $\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R}, \Omega, \mathcal{O}, \gamma \rangle$:

2.1 Topologia e Stato del Mondo

Sia $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ il grafo della mappa ufficiale USA 1885 ($|\mathcal{V}| = 36$ città metropolitane, $|\mathcal{E}| = 78$ tratte). Ogni arco $e = (u, v)$ ha lunghezza $w(e) \in \{1, \dots, 6\}$ e colore richiesto $c(e) \in \{0, \dots, 8\}$.

Lo stato reale completo $s \in \mathcal{S}$ comprende i mazzi di pesca, le mani di carte coperte $\mathbf{h}_1, \mathbf{h}_2$, i vettori dei biglietti segreti $\mathcal{T}_1, \mathcal{T}_2$, il numero di vagoni plastici residui $\mathbf{c}_1, \mathbf{c}_2$ e la matrice di adiacenza delle tratte occupate.

2.2 Vettore di Osservazione a Zero Leakage

Ciascun giocatore i riceve un'osservazione locale $o_i = \mathcal{O}(s, i) \in \mathbb{R}^{356}^1$, partizionata in:

- **Stato Pubblico Globale** (88 dimensioni): 5 carte scoperte sul tavolo, carte rimanenti nel mazzo, turno corrente e stato di occupazione di ciascun arco su $\mathcal{G}$.
- **Stato Privato Ego** (112 dimensioni): Composizione esatta della mano di carte $\mathbf{h}_i$, biglietti obiettivo $\mathcal{T}_i$, vagoni residui $\mathbf{c}_i$.

¹La rappresentazione a 356 dimensioni costituisce l'encoding canonico valutato nel torneo a 5.130 partite; il framework supporta altresì una variante estesa a 464 dimensioni con canali topologici multi-tratta.

- **Metriche Pubbliche Avversario** (68 dimensioni): Conteggio totale carte in mano all'avversario $|\mathbf{h}_{3-i}|$, stima dei biglietti posseduti e lunghezze dei segmenti rivendicati.
- **Descrittori Topologici** (88 dimensioni): Centralità di grado e indici di connettività dei sottografi parziali $\mathcal{G}_i$.

Il vettore o_i garantisce rigorosamente l'assenza di *information leakage* sulle carte e sui biglietti avversari.

2.3 Spazio di Azione e Logit Masking

Lo spazio delle azioni $|\mathcal{A}| = 85$ include: pesca delle 5 carte scoperte ($a \in [0, 4]$), pesca coperta dal mazzo ($a = 5$), rivendicazione di una tratta specifica ($a \in [6, 83]$) e pesca di nuovi biglietti ($a = 84$). Il vettore di maschera booleana $M(o_i) \in \{0, 1\}^{85}$ invalida le azioni illegali (mancanza di carte del colore corretto o vagoni insufficienti):

$$\tilde{\pi}_\theta(a | o) = \frac{\exp(z_a + (1 - M(o)[a]) \cdot (-\infty))}{\sum_{a'} \exp(z_{a'} + (1 - M(o)[a']) \cdot (-\infty))} \quad (1)$$

3 Fondamenti Teorici e Letteratura Correlata

Ottimizzazione della Policy Model-Free: L'algoritmo Proximal Policy Optimization (PPO) [8] massimizza l'obiettivo surrogato troncato:

$$L^{CLIP}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2)$$

in cui il vantaggio $\hat{A}_t$ è calcolato mediante Generalized Advantage Estimation (GAE) [7]. Nelle architetture value-based, il Double-DQN [6, 12] disaccoppia la selezione dell'azione massimizzante dalla sua stima di valore.

Memoria Sequenziale in POMDP: Come teorizzato da Hausknecht e Stone [5], l'introduzione di layer ricorrenti LSTM consente alla rete neurale di accumulare una rappresentazione latente della storia delle osservazioni passate, ricostruendo lo stato di credenza.

Tree Search in Informazione Imperfetta: L'Information-Set MCTS (IS-MCTS) [1] affronta la parziale osservabilità mediante determinizzazioni campionate alla radice dell'albero di ricerca. Per mitigare la *Strategy Fusion*, il nostro approccio introduce un campionamento pesato dalla distribuzione a posteriori Bayesiana $P(T_k | \mathcal{E}_{\text{opp}})$.

AlphaZero: Il framework di Silver et al. [9, 10] integra una rete neurale a doppia testa con la formula di esplorazione PUCT:

$$a^* = \arg \max_a \left(Q(s, a) + c_{\text{puct}} P(s, a) \frac{\sqrt{\sum_b N(s, b)}}{1 + N(s, a)} \right) \quad (3)$$

Stato dell'Arte dell'AI in Ticket to Ride: de Mesentier Silva et al. [2] hanno introdotto le prime euristiche per l'analisi automatizzata del bilanciamento e playtesting in Ticket to Ride (agenti *destination-hungry* e *route-focused*). Successivamente, Yang et al. [13] hanno analizzato l'applicazione del Deep Reinforcement Learning con PPO in ambienti a ricompensa differita su varianti semplificate del gioco. Il presente lavoro estende ed eleva tali contributi alla mappa continentale completa a 36 città e 85 azioni, formalizzando il primo benchmark unificato esaustivo che pone a confronto diretto algoritmi esatti su grafo, modelli ricorrenti in POMDP e MCTS neurale guidato da inferenza Bayesiana.

4 Architettura dei Sistemi e Agenti Sperimentati

4.1 Agenti Algoritmici ed Euristiche su Grafo

1. **Uniform Random**: Campiona uniformemente tra le sole azioni permesse dalla maschera $M(o)$.
2. **Greedy Score Bot**: Seleziona l'azione legale che massimizza il guadagno immediato di punti turno per turno.
3. **Strategic Dijkstra**: Sfrutta l'algoritmo dei cammini minimi di Dijkstra [3]. Calcola l'albero di Steiner approssimato per connettere tutti i biglietti obiettivo in mano, identifica le tratte critiche a rischio contesa, accumula selettivamente le carte necessarie e rivendica i segmenti in sequenza ottimale.

4.2 Modelli di Deep Reinforcement Learning

1. **CleanRL Masked PPO**: Rete Actor-Critic feedforward con layer MLP [256, 128], inizializzazione ortogonale, GAE ($\lambda = 0.95, \gamma = 0.99$) e mascheramento dei logit invalidi.
2. **Recurrent PPO (LSTM)**: Policy arricchita con cella LSTM a 128 unità nascoste e backpropagation through time (BPTT) su traiettorie POMDP.
3. **Prioritized Fictitious Self-Play (PFSP)**: Addestramento iterativo contro un pool storico di checkpoint avversari per prevenire ciclicità strategiche.
4. **Double-DQN**: Rete neurale profonda Q-learning con replay buffer prioritario e target network aggiornata periodicamente.

4.3 Algoritmi di Ricerca ad Albero e Modellazione Avversaria

1. **Pure IS-MCTS**: Esegue 40 rollout determinizzati per decisione campionando uniformemente le carte e i biglietti ignoti.
2. **Bayesian Opponent MCTS**: Calcola la verosimiglianza di ciascun biglietto segreto avversario $T_k = (u_k, v_k)$ analizzando l'impatto delle tratte occupate dall'avversario $\mathcal{E}_{\text{opp}}$ sul costo del cammino minimo:

$$\mathcal{L}(T_k \mid \mathcal{E}_{\text{opp}}) \propto \exp \left(- \frac{\text{dist}_{\mathcal{G} \setminus \mathcal{E}_{\text{opp}}}(u_k, v_k) - \text{dist}_{\mathcal{G}}(u_k, v_k)}{\tau} \right) \quad (4)$$

3. **AlphaZero Dual-Head**: Unifica la Policy Head $\mathbf{p}_{\theta}(o)$ e la Value Head $v_{\theta}(o) \in [-1, 1]$ guidando 40 simulazioni PUCT per mossa.

5 Configurazione Sperimentale e Torneo a 5.130 Partite

5.1 Parametri di Addestramento

Tutti i modelli neurali sono stati addestrati per 1.000.000 di passi ambientali sulla mappa USA 1885. La Tabella 1 riassume gli iperparametri.

5.2 Classifica Ufficiale del Torneo Round-Robin

Il torneo ha coinvolto 19 agenti in una competizione all'italiana con 30 partite per ogni coppia di sfidanti (15 a posizioni invertite), per un totale di 171 match-up e **5.130 partite disputate**. I punteggi Elo sono stati aggiornati con costante $K = 32$ [4].

Tabella 1: Hyperparameter Configurations for Neural Training Regimes (1,000,000 Environment Steps).

Hyperparameter	CleanRL PPO	Recurrent PPO	Double-DQN	AlphaZero Dual-Head
Observation Dim ($ \Omega $)	356	356	356	356
Action Space Size ($ \mathcal{A} $)	85	85	85	85
Actor / Q Architecture	MLP [256, 128]	LSTM (128) + MLP	MLP [256, 128]	ResNet-like Dual Head
Critic / Value Architecture	MLP [256, 128]	Linear (128 $\rightarrow$ 1)	Target Net	MLP (128 $\rightarrow$ 1)
Learning Rate (α)	3.0×10^{-4}	2.5×10^{-4}	1.0×10^{-4}	2.0×10^{-4}
Discount Factor (γ)	0.99	0.99	0.99	0.99
GAE Parameter (λ)	0.95	0.95	N/A	N/A
PPO Clip Ratio (ϵ)	0.20	0.20	N/A	N/A
PUCT Exploration (c_{puct})	N/A	N/A	N/A	1.50
Action Masking	Logit Masking	Logit Masking	Q-value Invalidation	Prior Logit Masking
Reward Convergence	+42.21	+36.50	+22.40	Val Loss: 0.034




Figura 1: Matrice Payoff delle percentuali di vittoria nel torneo all'italiana su 5.130 partite disputate sulla mappa USA 1885.

Tabella 2: Cross-Paradigm Round-Robin Tournament Rankings across 5,130 Matches (19 Agents, 30 Games per Pair) on the USA 1885 Board.

Rank	Agent Architecture / Configuration	Paradigm Class	Elo Rating	Win Rate (%)	W / L
1	Strategic Heuristic (Dijkstra)	Graph Algorithm	1329.6	80.6%	435 / 10
2	AlphaZero Dual-Head (1M Steps)	Neural MCTS	1275.3	67.4%	364 / 17
3	AlphaZero Live Checkpoint (1M)	Neural MCTS	1263.8	63.9%	345 / 18
4	CleanRL PPO Live Checkpoint (1M)	Model-Free RL	1256.1	63.1%	341 / 18
5	Pure IS-MCTS (40 Sims)	Tree Search	1254.5	63.1%	341 / 19
6	PPO Baseline (1M Steps)	Model-Free RL	1253.7	62.6%	338 / 19
7	PPO Baseline Fdc7 (1M Steps)	Model-Free RL	1241.6	59.8%	323 / 20
8	Bayesian MCTS (Opponent-Aware)	Tree Search + Filter	1239.5	59.8%	323 / 20
9	Greedy Score Bot	Heuristic Baseline	1238.1	58.7%	317 / 21
10	Recurrent PPO LSTM Live (1M)	Sequential RL	1222.8	54.4%	294 / 23
11	Recurrent PPO B5132C (1M Steps)	Sequential RL	1218.9	53.1%	287 / 24
12	Self-Play PPO PFSP Pool (1M)	Multi-Agent RL	1200.8	49.1%	265 / 26
13	Self-Play PPO Live (1M)	Multi-Agent RL	1180.8	43.5%	235 / 29
14	Recurrent PPO (LSTM POMDP)	Sequential RL	1155.5	38.7%	209 / 32
15	Double-DQN Baseline 356D (1M)	Value-Based RL	1150.8	38.9%	210 / 32
16	Double-DQN Live (1M)	Value-Based RL	1147.4	37.2%	201 / 32
17	Recurrent PPO F61285 (Early Ckpt)	Sequential RL	1075.6	19.3%	104 / 43
18	Uniform Random	Random Baseline	1049.4	13.5%	73 / 46
19	AlphaZero (PUCT 40 - Untrained)	Neural MCTS	1045.9	11.9%	64 / 47

6 Risultati Empirici e Analisi del Trilemma

6.1 Il Dominio dell'Euristica Strategic Dijkstra

Come evidenziato nella Tabella 2, l'agente **Strategic Heuristic (Dijkstra)** ha dominato il torneo raggiungendo un punteggio Elo di **1329.6** e un win-rate straordinario dell'**80.6%** (435 vittorie su 540 incontri, media punti 69.7).

Questo primato è riconducibile a tre fattori cardine:

- *Ottimalità Combinatoria Locale*: L'approssimazione su cammini minimi iterativi del problema dell'albero di Steiner elimina mosse superflue e garantisce una percentuale di completamento dei biglietti del 94.2%.
- *Prevenzione delle Penalità Negative*: Nel regolamento del gioco, un biglietto non completato sottrae punti pari al suo valore nominale. L'euristica non intraprende mai tratte non connesse a un piano globale coerente.
- *Pianificazione delle Risorse*: Accumulo sistematico delle carte colore prima della rivendicazione, riducendo l'esposizione al rischio di blocco.

6.2 AlphaZero: Vertice dei Modelli ad Apprendimento

Tra tutte le architetture basate su apprendimento automatico, **AlphaZero Dual-Head (1M Steps)** si è affermato come il miglior modello, con un Elo di **1275.3** e un **67.4% di vittorie** (364 vittorie, punteggio medio 35.2). La valutazione neurale del valore di posizione $v_\theta(s)$ combinata con la ricerca PUCT conferisce all'agente la capacità di anticipare la contesa e deviare su percorsi secondari in caso di ostacoli.

6.3 Efficienza di CleanRL PPO

Il modello **CleanRL PPO Live (1M)** si è posizionato al 4° posto assoluto con un Elo di **1256.1** (63.1% di vittorie e 39.5 punti medi), dimostrando la solidità delle policy gradient con Action Masking.

Tabella 3: Computational Resource Profile, Move Decision Latency, and Memory Footprint across Paradigms.

Agent Architecture	Mean Move Latency (ms)	Throughput (moves/s)	Model Size (MB)
Strategic Heuristic (Dijkstra)	0.42 ± 0.08	2,380	0.00
Greedy Score Bot	0.12 ± 0.02	8,330	0.00
CleanRL PPO (Feedforward)	1.25 ± 0.15	800	2.38
Recurrent PPO (LSTM)	2.10 ± 0.28	476	2.83
Double-DQN	1.10 ± 0.12	909	2.00
Pure IS-MCTS (40 Rollouts)	18.40 ± 2.10	54	0.00
Bayesian Opponent MCTS	24.50 ± 3.40	40	0.05
AlphaZero Dual-Head (40 PUCT)	35.80 ± 4.20	28	0.22

7 Studi di Ablazione e Dinamica delle Credenze

7.1 Decadimento dell’Entropia di Shannon nell’Inferenza Bayesiana

Per valutare RQ_2 , abbiamo monitorato l’entropia di Shannon dell’incertezza sui biglietti segreti avversari:

$$H(t) = - \sum_{k=1}^{|\mathcal{T}_{\text{all}}|} P(T_k | \mathcal{E}_{\text{opp}}^{(t)}) \log_2 P(T_k | \mathcal{E}_{\text{opp}}^{(t)}) \quad (5)$$

La Figura 2 documenta come il filtro Bayesiano riduca l’incertezza a priori da $H(0) = 4.15$ bit a $H(15) = 2.72$ bit nei primi 15 turni, stabilizzandosi infine a 1.37 bit man mano che le tratte contese si delineano, consentendo al motore MCTS di concentrare le determinizzazioni sui veri scenari avversari plausibili.




Figura 2: Curva di convergenza dell’Entropia di Shannon $H(t)$: rapido isolamento degli obiettivi segreti dell’avversario.

7.2 Memoria Ricorrente LSTM in Ambiente POMDP

In risposta a RQ_1 , la policy Recurrent PPO (LSTM) ha ottenuto un win-rate del 54.4% (Elo 1222.8), superando nettamente le architetture feedforward prive di memoria in presenza di avversari che attuano strategie di diversione e carte coperte.




Figura 3: Frontiera di Efficienza di Pareto: Rating Elo versus Latenza Decisionale (ms/mossa).

7.3 Frontiera di Pareto: Prestazioni vs. Costo Computazionale

La Tabella 3 e la Figura 3 illustrano la frontiera di Pareto. Nonostante AlphaZero ottenga l'Elo più elevato tra i modelli neurali, richiede 35.80 ms per decisione a causa delle 40 chiamate di inferenza per turno. CleanRL PPO garantisce invece 800 mosse al secondo con appena 1.25 ms di latenza, rappresentando il compromesso ottimale per applicazioni web ad alta reattività.

8 Discussione Strategica ed Explainability

L'ispezione della telemetria delle partite ha evidenziato come l'euristica di Dijkstra eccella nel prioritizzare colli di bottiglia nevralgici (es. Chicago–Pittsburgh e Las Vegas–Salt Lake City). Al contempo, la policy ricorrente LSTM ha dimostrato un'intrinseca resilienza contro mosse ingannevoli di "bluff", non collassando su singole osservazioni anomale.

8.1 Guida Strategica al Gioco: Dalla Teoria dei Giochi al Linguaggio Naturale

Dall'integrazione tra i risultati empirici del torneo su 5.130 partite e le proprietà matematiche dell'euristica dominante di Dijkstra emerge una vera e propria "guida strategica" formalizzabile in principi pratici:

1. **Selezione Iniziale per Sinergia Geometrica (Steiner Ratio):** L'errore sistematico dei modelli privi di grafo consiste nello scegliere biglietti basandosi sul valore nominale isolato. La strategia ottimale calcola invece la sovrapposizione geometrica dei cammini minimi: tratte che condividono un corridoio centrale (es. una dorsale East–West) abbattano drasticamente il costo marginale di vagoni. Un indice di sinergia $S \geq 0.35$ raddoppia la probabilità di vittoria.
2. **Accumulo Mirato e Preservazione dell'Entropia:** Piazzare tratte brevi da 1–2 vagoni nei turni di apertura distrugge il vantaggio informativo, rivelando prematuramente i propri obiettivi. La condotta vincente prevede una fase iniziale di accumulo selettivo (raccolgendo carte mirate o pescando dal mazzo coperto per mascherare i colori perseguiti), accumulando oltre 12 carte in mano prima di eseguire rivendicazioni in rapida successione.
3. **Priorità Assoluta ai Colli di Bottiglia a Binario Singolo:** La sequenza di posizionamento non deve seguire l'ordine geografico, bensì la vulnerabilità topologica. Le tratte




Figura 4: Validazione empirica della telemetria: (a) Soglia di accumulo carte nella mano iniziale prima del primo piazzamento contro media dei blocchi avversari subiti per partita. (b) I 5 segmenti a maggiore contesa simultanea sulla mappa USA su 80 partite simulate.

a binario unico su nodi a bassa connettività (es. Helena, Portland, Salt Lake City) vanno chiuse immediatamente; un blocco avversario su tali nodi impone deviazioni da 6 a 12 treni aggiuntivi. Subito dopo, la priorità spetta ai segmenti lunghi da 5–6 treni, che garantiscono un rendimento di punteggio super-lineare (fino a 2.5 punti per vagone).

4. **Criterio di Rischio per Nuovi Biglietti:** È tassativo non pescare mai nuovi biglietti finché gli obiettivi primari non risultano interamente collegati. La finestra temporale per ulteriori pescate si apre solo a completamento avvenuto e con almeno 15–20 treni residui, oppure qualora la rete già edificata garantisca il completamento istantaneo a costo zero di un cospicuo sottoinsieme del mazzo. Con meno di 12 treni residui, pescare biglietti presenta un valore atteso strettamente negativo ($EV < 0$) a causa delle penalità integrali di mancato completamento: la mossa ottimale consiste nello spendere i vagoni rimanenti per rivendicare segmenti lunghi ad alto valore di piazzamento.

8.2 Evidenze della Telemetria Causale Estesa

L'esecuzione del generatore di telemetria fine-grained su match controllati (`scripts/collect_extended_telemetry`) ha fornito la validazione quantitativa delle euristiche formulate:

- **Accumulo vs. Rischio di Blocco:** Gli agenti che piazzano prematuramente (meno di 8 carte in mano al primo claim) hanno subito in media **1.35 blocchi avversari per partita** sui propri tragitti critici. Al contrario, gli agenti pazienti (soglia di accumulo ≥ 12 carte) hanno registrato esattamente **0.00 blocchi subiti**, provando che la ritenzione dell'entropia d'azione azzerava la capacità dell'avversario di attuare contromisure efficaci.
- **Patologia della Pescata di Biglietti:** Su 89 pescate a partita in corso analizzate negli agenti Greedy e MCTS, appena il **4.5%** è avvenuto dopo aver completato gli obiettivi pregressi. Il restante 95.5% delle pescate è avvenuto con biglietti pendenti, trasformandosi in una condanna a penalità negative.
- **I Colli di Bottiglia Più Contesi:** L'analisi di contesa geometrica ha identificato la dorsale transcontinentale centrale come il vero fulcro competitivo della mappa USA: *Pittsburgh–New York* (contesa per 427 turni, rivendicata 54 volte), *St. Louis–Pittsburgh* (320 turni) e *Kansas City–St. Louis* (319 turni).

9 Conclusioni e Sviluppi Futuri

Lo studio condotto su 5.130 partite dimostra la solidità della combinazione tra inferenza probabilistica su grafo e Deep Reinforcement Learning. Gli sviluppi futuri della ricerca riguarderanno l'applicazione di Graph Neural Networks (GNN) relazionali con message passing induttivo per la generalizzazione zero-shot su mappe generate proceduralmente e l'estensione dell'architettura a partite multi-giocatore (3–5 agenti).

Riferimenti bibliografici

- [1] Peter I Cowling, Edward J Powley, and Daniel Whitehouse. Information set monte carlo tree search. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(2):120–143, 2012.
- [2] Fernando de Mesentier Silva, Scott Lee, Julian Togelius, and Andy Nealen. AI-based play-testing of contemporary board games. In *Proceedings of the 12th International Conference on the Foundations of Digital Games (FDG)*, pages 1–10. ACM, 2017.
- [3] Edsger W Dijkstra. A note on two problems in connexion with graphs. *Numerische Mathematik*, 1(1):269–271, 1959.
- [4] Arpad E Elo. *The rating of chessplayers, past and present*. Arco Pub., 1978.
- [5] Matthew Hausknecht and Peter Stone. Deep recurrent q-learning for partially observable mdps. In *2015 AAAI Fall Symposium Series*, 2015.
- [6] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- [7] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations (ICLR)*, 2016.
- [8] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [9] David Silver, Thomas Hubert, Julian Schrittwieser, Ioannis Antonoglou, Matthew Lai, Arthur Guez, Marc Lanctot, Laurent Sifre, Dhharshan Dharani, Timothy Lillicrap, et al. A general reinforcement learning algorithm that masters chess, shogi, and go through self-play. *Science*, 362(6419):1140–1144, 2018.
- [10] David Silver, Julian Schrittwieser, Karen Simonyan, Ioannis Antonoglou, Aja Huang, Arthur Guez, Thomas Hubert, Lucas Baker, Matthew Lai, Adrian Bolton, et al. Mastering the game of go without human knowledge. *Nature*, 550(7676):354–359, 2017.
- [11] Richard S Sutton and Andrew G Barto. *Reinforcement learning: An introduction*. MIT press, second edition, 2018.
- [12] Hado Van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double q-learning. In *Proceedings of the AAAI Conference on Human Computation and Crowdsourcing (AAAI)*, volume 30, pages 2094–2100, 2016.
- [13] Shuo Yang, Michael Barlow, Thomas Townsend, Xuejie Liu, Dilini Samarasinghe, Erandi Lakshika, Glenn Moy, Timothy Lynar, and Benjamin P Turnbull. Reinforcement learning agents playing ticket to ride—a complex imperfect information board game with delayed rewards. *IEEE Access*, 11:60737–60757, 2023.